


세 개의 AI 서비스, 그리고 그 뒤의 결정들.

지난 2년, 최신 모델 위에서 세 개의 AI 서비스를 설계하고 구현했다. 모델 돌레의 루프 — 라우팅, 검증, 실패 처리, 메모리 — 를 설계하는 일이었고, 이 포트폴리오는 그 결정들의 기록이다.

공민석

MINSEOK KONG — AI APPLICATION ENGINEER · SK 주식회사 AX · 2025.01 —



PDF 포트폴리오 ↓

EMAIL

GITHUB ↗

LINKEDIN ↗

01 원칙 — 세 시스템을 관통한 네 가지 기준 →

02 프로젝트 01 · 임원 인사 의사결정 에이전트 — 아키텍처 / 결정 기록 →

03 프로젝트 02 · HR 업무 통합 어시스턴트 — 9노드 파이프라인 →

04 프로젝트 03 · IT 변경관리 자동화 — RAG→LLM 6기능 →

05 기술 명세 · 출판물 · 기록 →

PRINCIPLES

원칙 — 선언이 아니라, 코드에 박혀 있다

세 시스템은 도메인도 구조도 다르지만, 방향을 정한 기준은 같았다. 아래 네 가지는 문서에 적어둔 다짐이 아니라 세 코드베이스 각각에서 확인되는 **실행되는 기준**이다 — 가장 깊게는 여기면 부팅이 거부되는 게이트(프로젝트 01)로 강제된다.

01

LLM / CODE

판단은 모델에게, 사실은 코드에게

생성의 자유와 사실의 결정론을 한 시스템 안에서 갈랐다. 임원 에이전트는 **도구가 유일한 데이터 통로**라 근거 없이 답할 길이 없고, HR 파이프라인은 도구 실행 순서를 LLM이 아니라 **입출력 의존성 위상정렬로 계산**하며(실행 계층 LLM 호출 0건), 변경관리 백엔드는 LLM이 고른 사례 ID로 담당자를 **DB에서 조회만** 한다. 환각이 사실 행세를 할 통로를 세 곳 모두 구조로 막았다.

증거 — P01 도구 밖 데이터 통로 0 · P02 실행 계층 **LLM 호출 0** · P03 사변 = 조회만

02

FAIL-MODE

실패를 먼저 설계한다

모든 컴포넌트에 "죽으면 어떻게 되는가"를 먼저 정했다. 권한 게이트는 **fail-closed**(의심되면 막는다), 기억·관측은 **fail-soft**(본 기능을 절대 깨뜨리지 않는다). 같은 인젝션 검

출기도 시스템이 다르면 실패 모드가 다르다 — 임원 에이전트는 **fail-over**(예비 검출로 전환), HR 파이프라인은 **fail-open**(오탐이 업무를 막지 않게). 실패 모드는 위협의 성질이 정한다 — "무조건 차단"은 설계가 아니다.

증거 — P01 **적대적 회귀 71 시나리오** · P02 권한 기본값 = 거부 · P03 30s SLA·부분 성공 집계

03

DATA-FIRST

정책은 코드가 아니라 데이터에 산다

코드는 해석 엔진이고, 도메인 지식은 데이터다. 모델의 행동을 정하는 것 — 도구 카탈로그·라우팅 규칙·프롬프트·판정 임계 — 을 세 시스템 모두 데이터로 선언했다. 임원 에이전트는 **신규 도구 추가에 중앙 코드 변경 0**(YAML 카탈로그 30개), HR 파이프라인은 **테넌트별 tools.yml 한 장**이 도구의 실행자·권한·순서를 정하며, 변경관리 백엔드는 **코드 안에 프롬프트가 0줄**이다. 검색 결합이 정책 파일 하나로 수리된 이유다(프로젝트 01 현장 기록).

증거 — P01 운영 YAML 30 · P02 **TOOLS.YML 단일 카탈로그** · P03 인라인 프롬프트 0

04

MAKE / BUY

만들 것과 빌릴 것을 가른다

후보 적합도 점수처럼 **전사가 공유할 알고리즘은 공용 서비스에 위임**하고(도구 26종 중 7종 = thin-proxy), 통제가 생명인 임원 에이전트의 **LLM 관측은 외부 의존 0으로 직접** 지었다(키 부재 시 no-op). 세 시스템 공통으로 LLM·임베딩 호출은 전부 **단일 게이트웨이 경유 — provider SDK 직접 호출 0건**. 모델 교체·비용 통제·벡터공간 정합이 한 지점에서 끝난다.


증거 — P01 **THIN-PROXY 7종**·자급 관측 엔진 · 세 시스템 SDK DIRECT CALL 0

PROJECT 01 — ARCHITECTURE

임원 인사 의사결정 에이전트

전사 임원이 실제 인사 의사결정에 쓰는 시스템. 질문은 예측할 수 없고, 데이터는 민감하며, 답에는 근거가 있어야 한다. 이 세 조건이 아래 구조 전부를 결정했다.

● 역할 — 애플리케이션 전 영역 설계·구현 · 2026.03 — 현재 운영



- 1 **부적격 요청은 추론에 닿기 전에 끝난다.** 권한 검사를 HTTP 경계로 끌어올려 신규 기능에도 자동 적용.
- 2 **자율에 코스를 준다.** 분류 전용 LLM이 17개 과제 중 책임 과제를 정하고 — 키워드 매칭이 아니라 의미 판단 — 루프는 그 범위 안에서만 자유. 분류가 죽어도 기본 경로로 계속(fail-open).
- 3 **추측으로 답할 길이 없다.** 도구가 유일한 데이터 통로 — 근거 없이 답하면 ENFORCER가 완료로 인정하지 않는다.
- 4 **검색 문서도 공격자일 수 있다.** 문서에 심긴 명령은 데이터 경계로 감싸 무력화(spotlighting) — 2차 주입 차단.

CACHE — 비용은 구조로 낸다

시스템 프롬프트를 **byte 단위로 동일한 정적부**와 턴마다 변하는 동적부로 물리 분리 — 캐시 적중이 우연이 아니라 **구조적으로 보장**되도록. 응답 지연과 토큰 비용이 함께 내려간다.

SCREEN CONTEXT — 화면을 아는 답변

사용자가 보고 있는 화면을 근거로 주입해 **"왜 이 후보인가"** 같은 지시대명사 질문에 답한다. 화면 데이터는 **변경 시에만 전송·캐시(비용)**, 사번·평가는 전 계층에서 마스킹(PII).

ORCHESTRATION — 한 턴의 LLM은 하나가 아니다

과제를 정하는 **분류기**, 공격을 거르는 **가드(병렬)**, 도구를 고르고 답을 합성하는 **메인(최대 12라운드)** — 일부 도구는 내부에서 또 LLM을 부른다: 후보를 병렬 생성해 **LLM-as-judge**로 거르거나, 하위 에이전트

를 통째로 재귀 실행한다. 라우팅조차 키워드가 아니라 모델의 판단이다.

75,540

LINES OF CODE

26 / 17

TOOLS / TASK TYPES

1,424

TEST FUNCTIONS

6

SEARCH INDEXES

전사 임원

ACTIVE USERS

PROJECT 01 — DECISIONS

이 시스템을 만든 네 가지 결정

구조는 우연이 아니라 선택의 결과다. 각 결정에는 대가가 있었고, 그 대가는 사람이 아니라 시스템이 지불하도록 설계했다.

DECISION 01 추론 경로를 미리 고정할 것인가

검토

고정 파이프라인 (DAG)

예측 가능하고 디버깅이 쉽다. 그러나 질문이 경로를 벗어나는 순간 무력해진다.

채택

자율 루프

임원의 질문은 검색 결과를 봐야 다음이 정해진다 — 경로 판단은 모델의 힘을 믿고 맡겼다.

COST 폭주와 비용 — 자율은 공짜가 아니다 **PAID BY**

턴 상한 · 중단 처리 · 자동 재시도의 3중 방어, 프롬프트를 정적/동적으로 쪼개 캐시 적중으로 비용 상환

DECISION 02 그 자율을 그대로 풀어줄 것인가

기각

채택

완전 자율

모든 도구를 열어두면 유연하지만 — 엉뚱한 경로, 불필요한 호출, 검증 불가가 함께 온다.

분류기 LLM의 제어 평면

턴마다 분류 전용 LLM이 책임 과제를 정해 도구를 좁히고 절차·필수 단계를 심는다 — 루프는 그 코스 안에서만 자유.

COST 턴마다 분류 호출 1회 **PAID BY**

공격 검출과 병렬 실행으로 지연 상쇄 — 분류가 죽어도 기본 경로로 계속(fail-open)

DECISION 03 프롬프트 유출, 가릴 것인가 잡을 것인가

시도 후 폐기

보호 문구를 출력에서 가리기

실제로 돌려 보니 정상 답변을 대량 오삭제 — 모델이 따라 쓰도록 준 템플릿과 원리적으로 충돌했다.

채택

추측 불가 canary 트립와이어

매 턴 심는 일회용 토큰이 나타나면 그때만 유출. 정상 답변 영향 0, 유출은 확정 탐지.

LESSON

탐지는 내용이 아니라 신호로 한다 — 실패한 A안의 원인 분석과 정정 이력까지 코드에 기록해 같은 실수를 봉인

DECISION 04 임베딩을 컴포넌트마다 따로 호출하게 둘 것인가

검토

각자 직접 호출

구현은 빠르다. 그러나 색인과 질의의 모델이 어긋나는 순간, 검색 품질이 소리 없이 무너진다.

채택

단일 매니저 일원화

색인·질의가 같은 경로를 지나므로 벡터공간 불일치가 구조적으로 불가능해진다.

RETURN 모델 교체 시 수정 지점 1곳 · 자격증명 분산 제거 · 캐시와 차원 검증을 한 지점에 캡슐화

현장 기록 — 운영 중 검증된 순간

같은 뜻이 문서마다 다른 표기로 적혀 적격 후보가 검색에서 빠지던 **recall 결함**이 보고됐다. 수정은 중앙 코드가 아니라 **동의어 확장 정책 파일 하나** — 정책을 데이터로 분리해 둔 설계가 스스로를 증명했다.

HR 업무 통합 어시스턴트

인사 데이터 조회·분석부터 조직 편성안과 평가·목표 초안 생성까지 — HR 매니저의 **23개 실무를 자연어 한 줄로 받아주는 단일 창구**. 서로 다른 업무가 한 입구로 들어오기에, 자유가 아니라 **정확한 라우팅**과 **검증 가능성**이 생명이었다.

● 역할 — 코어 추론 파이프라인 · 3계층 메모리 설계·구현 · 2025.07 — 2026.03

DECISION 05 여기서도 자율 루프인가

기각

자율 루프 (프로젝트 01과 동일)

23개 업무가 한 입구로 들어온다 — 영뚱한 도구로 새면 안 되고, 편성안·평가 초안은 인사 결정으로 곧장 이어진다.

채택


9노드 책임 분리 파이프라인

단계마다 검증하고, 단계마다 격리하고, 단계마다 교체 가능하게.

NOTE

같은 엔지니어가 문제에 따라 정반대 구조를 선택한 기록 — 구조는 취향이 아니라 문제의 성질이 정한다 (결정 01과 대조)

HYPERVISOR PIPELINE — 9 NODES · 이 중 7노드가 LLM-as-judge



* 판단은 LLM에게, 계산과 실행은 코드에게 — 06 실행순서(Kahn 위상정렬)·08 실행(순수 실행기) 2개 노드는 결정론
병렬 3중: 메모리 3중 동시 로드 · N개 도구 파라미터 동시 추출 · 파라미터 없는 도구는 LLM 호출 자체를 생략

← 옆으로 밀어 다이어그램 전체 보기 →

DECISION 06 실행 순서까지 LLM에게 맡길 것인가

기각

LLM이 순서도 판단

채택

데이터 흐름 기반 위상정렬

판단이 하나 늘 때마다 비결정성도 는다 — 순서가
틀리면 뒤의 모든 도구가 무너진다.

도구 간 입출력 의존성이 순서를 이미 결정한다. 계
산 가능한 것은 계산한다.

PRINCIPLE

힘을 쓸 자리를 정하는 것도 설계다 — 판단이 필요한 7개 노드에만 LLM을, 순서(06)와 실행(08)은 결정론으로

NONDETERMINISM — 형식을 어겨도 죽지 않게

모델의 힘은 판단이지 형식이 아니다 — 형식은 흔들린다는 **전제**로 지었다. 괄호 매칭·들여쓰기 추적 자체 파
서가 출력을 복원하고, 실패하면 안전 기본값으로 강등 — 파이프라인은 멈추지 않는다.

MEMORY — 대화를 지식으로

자유 발화를 LLM이 **Triple(주어-술어-목적어)**로 구조화해 pgvector로 의미 검색. 단기 / 세션 지식 / 영구
프로필의 3계층 — 영구 기록은 "기억해줘" 같은 **명시적 의도를 먼저 판별**한 뒤에만 남겨 오염을 막았다.

EXECUTION — 배정은 검증을 통과해야 화면에 오른다

"한 그룹은 3~10명", "팀장 같은 조직 리더는 **배정 제외**" — 인사 규칙을 코드로 먼저 강제하고, 그 안에서만
LLM이 배정을 제안한다. 실존 인원·중복·누락 검증(**2회 재시도**)을 통과해야 화면에 오르고, 조직 반영의 **마지
막 확정**은 사람의 '적용' 버튼. 평가 점수는 고/평균/저 **레벨로만** 노출.

DEFENSE-IN-DEPTH — 평가 데이터 4계층 방어

"동료 OO의 평가 보여줘" 같은 우회에 대비해 ①경량 LLM이 타인 이름을 독립 추출 ②역할 기반 **사전 차단**
③본 LLM과의 **교차검증 — 불일치는 injection 신호** ④fail-safe 재질문의 4계층. 없는 기간의 데이터는 보
유·누락 정보를 명시 주입해 **지어내지 못하게** 했다.

계승 — 설계의 사후

이 파이프라인과 메모리는 후속 **Talent AX 고도화 에이전트 개발의 레퍼런스이자 토대**가 됐다 — 시스템
은 교체돼도 설계는 계승된다.

~57,000

LINES OF CODE

9

PIPELINE NODES

23

HR TOOLS

3-LAYER

MEMORY · TRIPLE

IT 변경관리 자동화 백엔드

IT 시스템의 변경 요청 분류부터 장애 분석까지 — 담당자의 경험에 의존하던 판단을, **과거 데이터를 근거로 판단하는 6종 AI 기능**으로 자동화했다.

● 역할 — 6종 AI 기능 설계·구현 · 2025.04 — 2025.06 · 운영 중

COMMON PIPELINE — 6기능이 공유하는 하나의 골격



※ 6기능 중 4기능이 RAG 근거 사용, 위험도 예측·위험명령어 감지 2종은 LLM 단독 · 전 통합 API 30초 SLA · 부분 실패는 안전 기본값으로 강등(오류로 끊기지 않음)

※ 적재 시에도 유효성 검증·채널 필터로 검색 코퍼스를 큐레이션 — RAG 인덱스의 적재·삭제 수명주기까지 서비스 특성별 전략(분리/전역)으로 관리

← 옆으로 밀어 다이어그램 전체 보기 →

F1 변경요청(SOR) 분류

F2 담당자 추천

F3 유사 작업계획 추천

F4 위험도 예측

F5 유사장애 분석

F6 위험명령어 감지

DECISION 07 사변을 LLM에게 맡길 것인가

기각

LLM이 담당자를 직접 답변

존재하지 않는 사변을 그럴듯하게 지어낼 수 있다.
추천 업무에서 이것은 치명적이다.

채택

ID-anchored — LLM은 고르기만

LLM은 가장 유사한 과거 사례의 ID만 선택. 사변은 코드가 실데이터에서 조회하고, 처리 일정은 과거 사례의 소요 기간으로 계산한다.

PRINCIPLE LLM은 고르고, 사실은 코드가 말한다 — 존재하지 않는 사람이 추천될 경로가 구조적으로 없다

DECISION 08 LLM 출력을 그대로 시스템에 넣을 것인가

기각

JSON 스키마로 강제

채택

줄 단위 라벨·구분자 프로토콜

표준적이지만 형식이 조금만 깨져도 응답 전체를 잃는다 — 긴 스키마는 토큰도 비싸다.

분류·이유 라벨과 구분자로 받아 한 줄이 깨져도 나머지를 복원하고, 값은 정해진 enum으로만 수렴시킨다.

RETURN

형식 오류가 국소화되고 시스템에는 닫힌 값만 들어간다 — 파싱 실패조차 안전 기본값(unknown·하)으로 강등

SELF-VERIFICATION — 검색을 믿지 않는다

벡터 검색이 물어온 사례도 무관할 수 있다. LLM이 사례마다 **검증 플래그를 스스로 판정**하게 하고, 통과한 사례만 채택해 중복 제거 후 최신순으로 재정렬 — 유사도는 검색이, 시점은 코드가 정한다.

PROMPT-AS-CONFIG — 코드에 프롬프트 0개

모델의 행동을 결정하는 프롬프트를 전부 코드 밖 YAML로 분리했다. 지시·출력 형식·few-shot 예시를 **데이터로 다루므로** 프롬프트 개선과 실험이 **코드 배포 주기에서 분리**된다 — AI 품질을 조정하는 손잡이가 코드가 아니라 데이터에 있다.

8,721

LINES OF CODE

6

AI FUNCTIONS

4

AI WORKFLOWS

0

SDK DIRECT CALLS

TECHNICAL DATA

기술 명세

AGENT RUNTIME

자율 루프와 책임 분리 파이프라인 양쪽을 설계 · tool calling 오케스트레이션(병렬 실행 · 의존성 위상정렬) · 한 턴 멀티 LLM(분류기·가드 병렬) · **프롬프트 캐싱 설계**(정적/동적 분리 · cache affinity) · 서브에이전트 fork 격리 · SSE 스트리밍

MEMORY & CONTEXT

컨텍스트 엔지니어링 — supersession(valid-time) 장기기억 · Triple(주어·술어·목적어) 구조화 기억 · pgvector 의미 회상 + RRF 재랭킹 · **화면 컨텍스트 grounding** · 대용량 결과 자동 요약

RETRIEVAL

하이브리드 검색(BM25 · 벡터 · 시맨틱, RRF 융합) · 권한 필터 내장 검색(fail-closed) · 임베딩 경로 단일화(3072d 단일 매니저) · RAG-grounded 합성(추정 금지)

TRUST & SAFETY

프롬프트 인젝션 검출(guard LLM + 정규식 fail-over) · **spotlighting** · **canary 트립와이어** · 환각 방지 게이트(fail-closed) · **ID-anchored 환각 차단** · PII 마스킹(기억·관측 계층) · **LLM-as-Judge 평가 파이프라인** · 적대적 회귀 시나리오

PLATFORM & OPS

YAML-first 확장(중앙 코드 변경 없이 도구·정책 추가) · 멀티테넌트 설정 분리 · AST 린트 게이트 · 부팅 drift 게이트 · 교차 서비스 계약 테스트 · **LLM 관측**(Langfuse 트레이싱 · 토큰 비용) · OpenTelemetry · 맥등 배치 · **폐쇄망 CI/CD 배포**

STACK

Python · FastAPI · Pydantic v2 · SQLAlchemy(async) · asyncpg · PostgreSQL · **pgvector** · Redis · **Azure AI Search** · Azure OpenAI · LangGraph(checkpointer·store) · **LangMem**(기억 추출·저장) · Docker · Kubernetes · GitHub Actions

ML FOUNDATION

모델 경량화·최적화(OpenVINO, PTQ) · 심층강화학습 앙상블 7종(A2C·DDPG·PPO·ACKTR·SAC·TD3·TRPO) · 자기 지도 학습(DINO ViT · 마스킹 특징 복원) · Computer Vision(YOLOv8 · 단안 깊이 추정 · 비지도 의미론적 분할) — 기록 섹션의 연구 [1]·[2]·[3]으로 검증

PUBLICATIONS & RECORD

Simulating Mobile Robot Vision: An Analysis of RGB-D versus RGB-Based Distance Accuracy and CPU Optimization

[1] IEEE ICAIIC 2025 · KONG, M., PARK, J., LEE, D., KOURTZANIDIS, N., SO, J. · [IEEE XPLORE ↗](#)

GPU 없는 **CPU-only** 로봇 비전을 ROS로 실시간 시뮬레이션 — YOLOv8 Nano 인간 탐지에 MobileNetV2(KITTI) 단안 깊이 추정과 RGB-D 실측의 거리 정확도를 비교했다. 하드웨어 특화 (OpenVINO 변환)와 하드웨어 불문(PTQ 양자화) **이중 최적화로 CPU 사용량 약 4.6–5.3% 절감** — 엣지 장비의 자원 제약을 모델 최적화로 상환하는 설계를 실증.

Empirical Analysis of Automated Stock Trading Using Deep Reinforcement Learning

[2] MDPI APPLIED SCIENCES 2023 (SCIE) · KONG, M., SO, J. · CITED BY 29 (GOOGLE SCHOLAR) · [MDPI ↗](#)

7종 심층강화학습 알고리즘(A2C·DDPG·PPO·ACKTR·SAC·TD3·TRPO)을 결합한 앙상블 에이전트 **Remake Ensemble**을 구축하고, Dow Jones 단일 검증에 머물던 기존 연구를 KOSPI-JPX까지 넓혀 **에이전트당 5회 반복 실험**으로 실증했다. 알고리즘 수보다 **시장별 액션(전략) 설계가 수익 안정성을 좌우함**을 규명 — 보수적 전략 전환으로 KOSPI-JPX 성능 개선을 확인. 화려한 주장 대신 실험으로 경계를 확정하는 검증 태도의 출발점.

Unsupervised Semantic Segmentation Leveraging Masking-Based Feature Reconstruction

[3] 서강대학교 대학원 2024.06 · KONG, M. (지도: Prof. Jungmin So)

MAE의 마스킹 복원 아이디어를 이미지가 아닌 **특징(feature) 레벨로 확장한 RMF(Reconstructing Masked Feature)** 제안 — DINO(ViT) 특징의 50%를 패치 단위로 마스킹하고 복원하도록 세그멘테이션 헤드를 학습시켜, 레이블 없이 픽셀을 의미 단위로 분할한다. 마스킹 비율 3종·방식 4종 ablation으로 설계값을 실증 선택했고, CocoStuff·Cityscapes에서 DINO 베이스라인 대비 **비지도 픽셀 정확도 최대 +23.8%p · mIoU 최대 +5.1%p** — 3개 트랜스포머 백본(ViT-S/8·S/16·B/8) 전반의 일관 향상을 검증.

SK 주식회사 AX AI Application Engineer

2025.01 — PRESENT

서강대학교 M.S. Computer Science & Engineering — Major in Applied Big Data Engineering (Prof. Jungmin So)

2022.02 — 2024.08

University of Toronto Applied Science & Engineering — IITP Applied AI Program

2024.01 — 2024.06

서강대학교 B.S. Economics · Bigdata Science

2014.02 — 2022.02

RECORD — CERTIFICATION & LANGUAGE

빅데이터분석기사 국가기술자격 — 과학기술정보통신부·통계청 (한국데이터산업진흥원)

2024.12

OPIc English — AL (Advanced Low) ACTFL 공인 말하기 평가

2024.09 — 2026.08

Agent loops, retrieval, guardrails — in production.

[PDF 포트폴리오](#) ↓ · [GITHUB](#) ↗ · [LINKEDIN](#) ↗

© 2026 MINSEOK KONG

CONTACT

공민석 ksjscott@naver.com